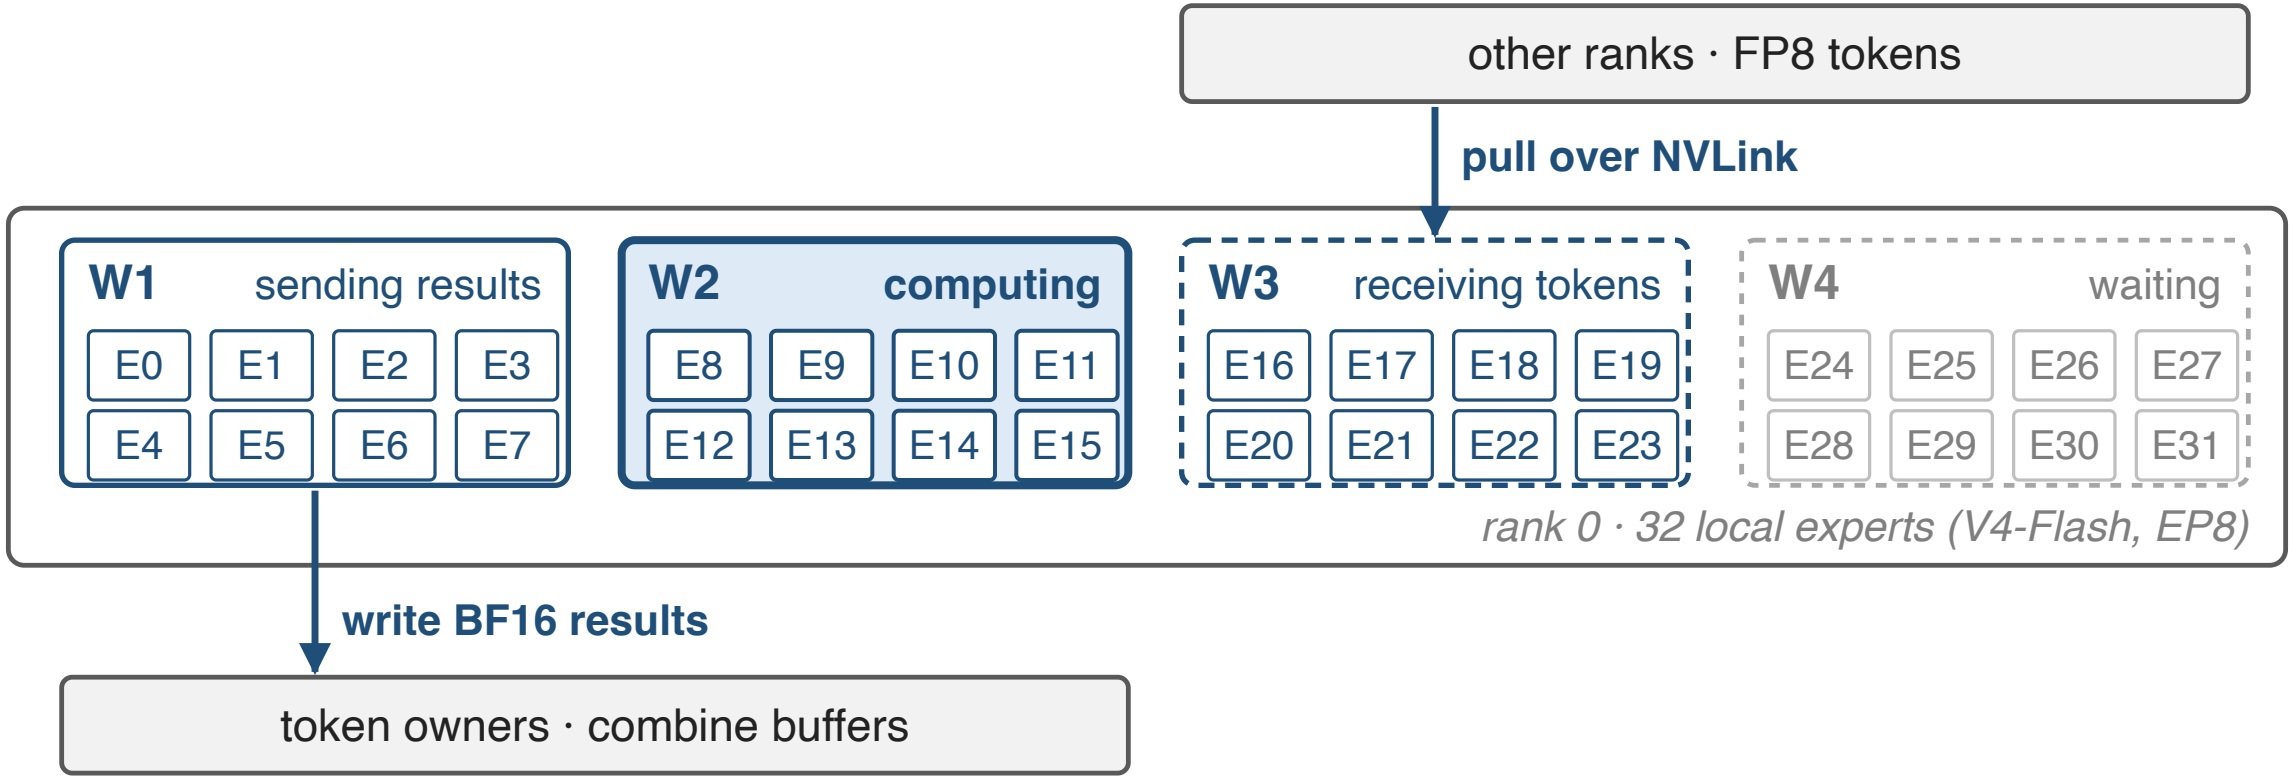

other ranks · FP8 tokens
pull over NVLink
W1
sending results
E0
E1
E2
E3
E4
E5
E6
E7
W2
computing
E8
E9
E10
E11
E12
E13
E14
E15
W3
receiving tokens
E16
E17
E18
E19
E20
E21
E22
E23
W4
waiting
E24
E25
E26
E27
E28
E29
E30
E31
rank 0 · 32 local experts (V4-Flash, EP8)
write BF16 results
token owners · combine buffers